LAPORAN UJIAN TENGAH SEMESTER MATA KULIAH *MACHINE LEARNING* TK-45-GAB-G04

Pengolahan Dataset RegresiUTSTelkom menggunakan Regression Model

Disusun untuk memenuhi UTS mata kuliah Machine Learning di Program Studi S1 Teknik Komputer

Disusun oleh:

MUHAMMAD RAFINDHA ASLAM 1103213080



FAKULTAS TEKNIK ELEKTRO UNIVERSITAS TELKOM BANDUNG

2024

1. Latar Belakang

Model regresi memiliki peran penting dalam memprediksi nilai target berdasarkan fitur tertentu, khususnya dalam data science dan machine learning. Pemilihan model yang optimal memerlukan evaluasi parameter model menggunakan teknik seperti hyperparameter tuning untuk meningkatkan akurasi prediksi. Pada tugas ini, dilakukan tuning hyperparameter untuk empat model regresi: Polynomial Regression, Decision Tree, k-Nearest Neighbors (k-NN), dan XGBoost.

Model ini diterapkan pada dataset yang berisi data numerik dengan target kolom 2001. Dataset ini memiliki beberapa nilai kosong (missing values) yang perlu ditangani melalui preprocessing. Dataset ini mencakup berbagai fitur sebagai prediktor, dengan target 2001 merepresentasikan variabel dependen yang akan diprediksi menggunakan model regresi.

2. Tujuan

- 1) Melakukan hyperparameter tuning untuk menemukan parameter terbaik dari setiap model regresi.
- 2) Mengevaluasi performa model menggunakan metrik seperti Mean Squared Error (MSE), Mean Absolute Error (MAE), dan R² Score.
- 3) Membandingkan hasil tuning untuk menentukan model yang paling optimal berdasarkan dataset yang diberikan.

3. Metode

1) Preprocessing Data:

- Mengatasi nilai kosong (missing values) menggunakan SimpleImputer dengan strategi imputasi rata-rata (mean).
- Membagi dataset menjadi training (80%) dan testing (20%).
- Sampling 20% data training untuk efisiensi memori saat tuning hyperparameter.

2) Hyperparameter Tuning:

- Menggunakan RandomizedSearchCV untuk mengurangi beban komputasi dengan parameter grid yang lebih sederhana.
- Menggunakan validasi silang (cross-validation) sebanyak 2 folds.

3) Evaluasi:

- Mengevaluasi model berdasarkan MSE, MAE, dan R² Score.
- Membandingkan performa model untuk memilih model terbaik.

4. Code

1) Bagian 1: Exploratory Data Analysis (EDA)

```
Import necessary libraries for EDA
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
data = pd.read csv('RegresiUTSTelkom.csv') # Ensure the file path is
print("Dataset Information:")
print(data.info())
print("\nDataset Description:")
print(data.describe())
# Calculate the number of rows and columns for the layout
num cols = data.shape[1] # Get the number of columns
data.hist(bins=15, figsize=(15, 4 * num rows), layout=(num rows, 4))
plt.suptitle("Feature Distributions")
plt.tight layout()  # Adjust subplot params for a tight layout
plt.show()
plt.figure(figsize=(10, 8))
sns.heatmap(data.corr(), annot=True, cmap='coolwarm')
plt.title("Correlation Heatmap")
plt.show()
```

Bagian 2: Preprocessing dan Pipeline Setup

```
# Import necessary libraries for data processing, pipelines, models, and metrics
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
from sklearn.tree import DecisionTreeRegressor
from sklearn.neighbors import KNeighborsRegressor
from xgboost import XGBRegressor
```

```
from sklearn.model selection import train test split, GridSearchCV
from sklearn.metrics import mean squared error, mean absolute error,
r2 score
import pandas as pd
data = pd.read csv('RegresiUTSTelkom.csv') # Ensure file path is
# Split the data into features and target
print("Column names in the dataset:", data.columns)
X = data.drop('2001', axis=1) \# Replace '2001' with the actual target
y = data['2001'] # Target variable
X train, X test, y train, y test = train test split(X, y,
test size=0.2, random state=42)
poly pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('poly features', PolynomialFeatures(degree=2)),
    ('regressor', DecisionTreeRegressor())
])
dt pipeline = Pipeline([
    ('regressor', DecisionTreeRegressor())
knn pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('regressor', KNeighborsRegressor())
xgb pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('regressor', XGBRegressor())
])
print("Pipelines created successfully.")
```

Bagian 3: Polynomial Regression Tuning

```
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
```

```
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
from sklearn.tree import DecisionTreeRegressor
from sklearn.model selection import RandomizedSearchCV
poly pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='mean')), # Handle missing
    ('scaler', StandardScaler()),
    ('poly features', PolynomialFeatures(degree=2)),
    ('regressor', DecisionTreeRegressor())
])
poly params = {
    'poly features degree': [2], # Only degree 2
poly search = RandomizedSearchCV(
   poly pipeline,
    param distributions=poly params,
    cv=2,
    scoring='neg mean squared error',
    n jobs=1,
    verbose=2,
poly search.fit(X train sample, y train sample)
results['Polynomial Regression'] = {
    "Best Parameters": poly search.best params ,
    "Evaluation": evaluate model(poly search.best estimator , X test,
y test)
print("Best Polynomial Regression Parameters:", results['Polynomial
Regression']['Best Parameters'])
print("Evaluation Metrics:", results['Polynomial
```

Bagian 4: k-Nearest Neighbors Tuning

```
# Update k-NN pipeline with imputer
knn_pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='mean')), # Handle missing
values by imputing the mean
    ('scaler', StandardScaler()),
    ('regressor', KNeighborsRegressor())
])
```

Bagian 5: XGBoost Tuning

```
knn params = {
    'regressor n neighbors': [3, 5, 7],
knn search = RandomizedSearchCV(
    knn pipeline,
    param distributions=knn params,
    scoring='neg mean squared error',
    n jobs=1,
    verbose=2,
    random state=42
knn search.fit(X train sample, y train sample)
results['k-Nearest Neighbors'] = {
    "Best Parameters": knn search.best params ,
xgb params = {
    'regressor n estimators': [50, 100, 200],
xgb search = RandomizedSearchCV(
    xgb pipeline,
    param distributions=xgb params,
    cv=2,
```

```
scoring='neg_mean_squared_error',
    n_jobs=1,
    verbose=2,
    random_state=42
)
xgb_search.fit(X_train_sample, y_train_sample)
results['XGBoost'] = {
    "Best Parameters": xgb_search.best_params_,
    "Evaluation": evaluate_model(xgb_search.best_estimator_, X_test,
    y_test)
}
# Display the results for each model
for model_name, result in results.items():
    print(f"\nModel: {model_name}")
    print("Best Parameters:", result["Best Parameters"])
    print("Evaluation Metrics:")
    for metric, value in result["Evaluation"].items():
        print(f" - {metric}: {value}")
```

5. Analisis

- Polynomial Regression: Performa sangat rendah (R² = 0.064, MSE = 112.83), menunjukkan model ini tidak efektif dalam menjelaskan variabilitas data.
- 2) k-Nearest Neighbors: Sedikit lebih baik dari Polynomial Regression (R² = 0.196, MSE = 96.89), tetapi hasilnya masih kurang optimal.
- 3) XGBoost: Memberikan hasil terbaik dengan R² = 0.317 dan MSE = 82.34, menunjukkan kemampuan menangkap pola data lebih baik dibandingkan model lainnya.

6. Kesimpulan

Berdasarkan evaluasi terhadap tiga model, XGBoost adalah pilihan terbaik untuk tugas ini karena memiliki akurasi tertinggi dengan R² sebesar 0.317 dan MSE terendah, menunjukkan kemampuannya yang superior dalam menangkap pola data dibandingkan Polynomial Regression dan k-Nearest Neighbors.